

Домашнее задание #2

Kaggle Competition: Feature Engineering & Ансамбли

Курс ML Start 2026

Дедлайн: воскресенье, 02.08.2026, 23:59

Суть задания

Время применить знания на практике. Выбираете завершённое соревнование на Kaggle, делаете решение и стремитесь попасть в топ результатов по публичному лидерборду.

Минимальная цель: топ 25% (верхняя четверть)

Амбициозная цель: топ 5–10% (для тех, кто хочет челлендж)

Это задание сложнее первого – здесь важен не только baseline, но и итерации улучшений: feature engineering, подбор моделей, ансамбли, работа с переобучением.

Что нужно сделать

1. Выбрать завершённое соревнование из списка ниже (или предложить своё, но согласуйте).
2. Изучить данные и задачу:
 - Внимательно прочитать описание соревнования
 - Понять метрику оценки (RMSE, LogLoss, F1, MAE и т. д.)
 - Посмотреть топовые публичные ноутбуки – не для копирования, а чтобы понять baseline
3. Провести полноценный ML-пайплайн:
 - EDA и визуализация
 - Feature engineering (создание новых признаков, трансформации)
 - Обучение нескольких моделей
 - Подбор гиперпараметров
 - Создание ансамблей (стекинг, блендинг, voting)
 - Кросс-валидация с той же метрикой, что в соревновании
4. Сделать submission на Kaggle и зафиксировать свой результат в публичном лидерборде.
5. Задokumentировать процесс: что попробовали, что сработало, что нет, как улучшали решение итерациями.

Соревнования на выбор

Ниже – список завершённых соревнований разной сложности. Все имеют активный лидерборд для поздних сабмитов. Только табличные данные и классический ML (никаких нейросетей, RL или временных рядов).

Соревнование		Задача	Сложность	Ссылка
Spaceship Titanic		Бинарная классификация	Средняя	https://www.kaggle.com/c/spaceship-titanic
Porto Seguro Safe Driver		Бинарная классификация	Средняя	https://www.kaggle.com/c/porto-seguro-safe-driver-prediction
Santander Transaction	Customer	Бинарная классификация	Высокая	https://www.kaggle.com/c/santander-customer-transaction-prediction
Home Credit Default Risk		Бинарная классификация	Высокая	https://www.kaggle.com/c/home-credit-default-risk
Elo Recommendation	Merchant	Регрессия	Высокая	https://www.kaggle.com/c/elo-merchant-category-recommendation
Santander Prediction	Value	Регрессия	Средняя	https://www.kaggle.com/c/santander-value-prediction-challenge

Рекомендации по выбору:

- Для топ 25%: Spaceship Titanic, Porto Seguro, Santander Value Prediction
- Для топ 5–10%: Home Credit, Santander Customer Transaction, Elo (потребуется больше работы)

Можно взять другое завершённое соревнование, но оно должно:

- Иметь активный лидерборд (можно делать late submissions)
- Быть не слишком простым (>1000 участников)
- Быть табличной задачей классического ML (не CV, не NLP, не временные ряды, не DL)
- Не быть из списка «заезженных» (Titanic, House Prices, Iris и т. д.)

Что должно быть в решении

Это не просто «обучить модель», а полноценный пайплайн. Чеклист:

✓ EDA: распределения, корреляции, пропуски, аномалии, инсайты о данных

- ✓ Feature Engineering: создание новых признаков (минимум 3–5 осмысленных)
- ✓ Несколько моделей: минимум 3–4 разных (например: XGBoost, LightGBM, CatBoost, LinearModel)
- ✓ Подбор гиперпараметров: Grid/RandomSearch или Optuna/Hyperopt
- ✓ Кросс-валидация: с метрикой соревнования (важно!)
- ✓ Ансамбль: стекинг, блендинг или weighted voting из лучших моделей
- ✓ Submission: скриншот с результатом на публичном лидерборде
- ✓ Итерации: документация того, что пробовали и как улучшали (baseline → final)

Важно: Не копируйте чужие решения. Можно смотреть идеи и подходы, но код и логика должны быть вашими.

Можно объединить ноутбуки в один, но структура должна быть читаемой.
README.md должен содержать:

- Название соревнования и ссылка
- Ваш публичный результат и место в лидерборде
- Краткое описание подхода (baseline → улучшения → финальное решение)
- Что сработало лучше всего
- Что не сработало (это тоже важно!)
- Инструкции по воспроизведению результата

Обязательно:

- Скриншот вашего результата на Kaggle (с видимым username и score)
- Файл submission.csv, который дал финальный результат

Ссылку на репозиторий скинуть до дедлайна.

Важно: Попасть в топ 5% с грязным кодом – это хуже, чем топ 20% с чистым пайплайном и хорошей документацией. Мы оцениваем процесс, не только результат.

Советы

- Начните с baseline: простая модель на сырых данных → посмотрите на результат
- Итеративно улучшайте: добавляйте фичи по одной, смотрите на CV score
- Читайте discussions: в топовых соревнованиях много полезных инсайтов
- Следите за переобучением: CV score должен коррелировать с LB score
- Документируйте всё: что пробовали, что сработало, что нет (это поможет в README)
- Используйте кросс-валидацию: именно с той метрикой, что в соревновании
- Ансамбли решают: в топовых решениях почти всегда есть стекинг/блендинг

Частые ошибки

- Копирование чужого кода без понимания
- Data leakage (утечка таргета в признаки)
- Переобучение на train и плохой результат на test
- Неправильная кросс-валидация (стратификация классов, корректные фолды)
- Игнорирование метрики соревнования (оптимизируют не то)

Дедлайн: воскресенье, 2 августа 2026, 23:59

По всем вопросам пишите – @artemovma