

Кредитный скоринг: Home Credit Default Risk

Анализ вклада кредитной истории, моделей и признаков

Цель проекта. Построить модель риска дефолта и последовательно проверить, откуда появляется качество: сколько даёт переход от линейной модели к boosting, насколько помогает подробная кредитная и платёжная история, какие источники истории наиболее полезны и переносятся ли локальный прирост ансамбля на скрытый leaderboard.

Финальный результат. CatBoost на полной матрице получил **0.79405 OOF ROC-AUC**, **0.28957 PR-AUC** и **0.06541 Brier**. На Kaggle: **0.79479 Public** и **0.79510 Private**. Cross-fitted blend дал 0.79440 OOF, но на Kaggle оказался слабее, поэтому финальной моделью оставлен CatBoost.

1. Постановка задачи и дизайн эксперимента

В `application_train.csv` находится 307 511 кредитных заявок. `TARGET=1` соответствует проблемам с погашением кредита. Положительный класс составляет только 8.07%, поэтому ассигасу не отражает качество риск-скоринга: модель должна прежде всего правильно *ранжировать* клиентов по риску.

Основная метрика — ROC-AUC, совпадающая с метрикой соревнования. PR-AUC дополнительно показывает качество на редком положительном классе, Brier score — насколько разумна шкала вероятностей.

Эксперимент организован как последовательная проверка гипотез:

1. Logistic Regression и одиночное дерево как простые baseline;
2. LightGBM только по текущей заявке;
3. тот же LightGBM после подключения истории;
4. CatBoost и MLP на полной матрице;
5. независимая проверка blend через второй уровень CV;
6. permutation importance, SHAP, ошибки и fairness.

Это позволяет не просто сообщить лучший score, а отделить эффект модели от эффекта *дополнительных данных*. При этом `EXT_SOURCE_1/2/3` уже находятся в основной анкете, поэтому вариант «только заявка» означает отсутствие подробных исторических таблиц Home Credit, а не абсолютное отсутствие внешней кредитной информации.

2. Данные и EDA

Используются `application_train/test`, `bureau`, `bureau_balance`, `previous_application`, `POS_CASH_balance`, `installments_payments` и `credit_card_balance`. Исторические таблицы имеют более мелкую гранулярность: на клиента приходится много кредитов и платежей. Поэтому каждый источник сначала агрегируется до одной строки на `SK_ID_CURR`; merge выполня-

ется с проверкой one-to-one, и итоговое число train-строк остаётся 307 511.

EDA показал четыре важных свойства данных. Во-первых, сильный дисбаланс классов. Во-вторых, пропуски потенциально информативны: отсутствие внешнего score или конкретного типа истории может характеризовать клиента. В-третьих, финансовые суммы имеют длинные правые хвосты, поэтому правдоподобные крупные значения не удаляются автоматически. В-четвёртых, `DAYS_EMPLOYED=365243` является техническим значением: оно заменяется на пропуск, а факт аномалии сохраняется отдельным признаком.

Наиболее сильным исходным сигналом визуально и далее по importance оказываются `EXT_SOURCE`. Default rate также заметно меняется с возрастом и полом, поэтому эти группы позже анализируются отдельно в fairness-блоке, без причинной интерпретации.

3. Feature engineering

Финальная матрица содержит **2 708 признаков**, из них 16 категориальных. Вторая итерация feature engineering добавила **1 082 признака** и была направлена на более точное описание *давности событий* и *структуры отдельных договоров*.

Для анкеты строятся отношения кредита и анкетиста к доходу, показатели на члена семьи, агрегаты и взаимодействия `EXT_SOURCE`, разница между суммой кредита и стоимостью товара, возраст и характеристики занятости.

Для `bureau` используются долг, просрочка, лимиты, активные/закрытые кредиты и временные окна 180/365/730/1095 дней. Для `previous applications` — аналогичные окна и последние 1/3/5 заявок. Для POS и credit cards рассчитываются окна 3/6/12/24 месяца, для `installments` — 90/180/365/730 дней. На уровне платежей строятся недоплата, payment ratio, days late/early и флаги проблемного платежа.

Для POS, `installments` и `credit cards` дополни-




Рис. 1: EDA основной заявки: дисбаланс классов и различия default rate по демографическим группам. Графики используются как описание данных, а не как доказательство причинных связей.

тельно применяется двухуровневая схема

операции → договор → клиент,

которая позволяет различать единичную проблемную сделку и систематические проблемы по нескольким договорам.

Почему временные окна важны

Обычная агрегация «за всю историю» смешивает события разной давности. Для риска клиента просрочка месяц назад и просрочка три года назад не обязаны нести одинаковый сигнал. Временные окна позволяют модели отдельно видеть недавнее состояние клиента; ниже permutation importance показывает, что именно это семейство оказалось самым сильным среди новых v2-признаков.

4. Валидация

Все модели сравниваются на одной схеме: 5 стратифицированных фолдов с перемешиванием и фиксированным `random state=2026`. Каждый train-объект получает OOF prediction от модели, которая его не видела. Итоговые ROC-AUC, PR-AUC и Brier считаются по единому OOF-вектору.

Для LightGBM, CatBoost и MLP внешний validation fold не участвует в early stopping: внутри outer-train выделяется отдельный holdout. Таким образом, внешний fold используется только для оценки.

В blend добавлен ещё один уровень защиты. Вес CatBoost/LightGBM подбирается на четырёх пятых OOF-прогнозов и проверяется на остав-

шейся пятой. Поэтому reported gain ансамбля не является результатом подбора веса на тех же объектах, на которых затем измерен score.

5. Что дало основной прирост

Logistic Regression получает **0.75141 ROC-AUC**; одиночное дерево — 0.72805. Значит, простая нелинейность в виде одного дерева сама по себе не решает задачу.

LightGBM только по текущей заявке даёт **0.76724**: это +0.01583 к линейному baseline. Следовательно, уже в анкете есть полезные нелинейные взаимодействия между внешними score, кредитной нагрузкой, возрастом и другими параметрами.

После добавления истории тот же LightGBM получает **0.78538**. Прирост +0.01814 при сохранении семейства модели — наиболее прямое подтверждение основной гипотезы: прошлые кредиты и платежи дают существенный дополнительный сигнал.

CatBoost на той же полной матрице достигает **0.79405**, то есть ещё +0.00867. Его fold ROC-AUC лежит примерно в диапазоне 0.7922–0.7954, поэтому выигрыш не определяется одним удачным разбиением.

Интерпретация последовательности

От LogReg до CatBoost общий локальный прирост составляет +0.04264 ROC-AUC. Примерно 37% этого прироста появляется уже при переходе к нелинейному LightGBM по анкете, ещё около 43% — после подключе-




Рис. 2: Последовательное изменение OOF ROC-AUC. Наибольший прирост дают переход к boosting и подключение подробной истории; вклад blend значительно меньше.

ния истории, оставшаяся часть — за счёт более подходящего для финальной матрицы CatBoost. Это делает историю не косметическим дополнением, а одним из двух главных источников качества.

6. ROC, PR и калибровка

ROC- и PR-кривые подтверждают табличное сравнение: CatBoost и LightGBM с историей находятся выше простых моделей на большей части диапазона порогов. PR-AUC особенно важен при 8% дефолтов: CatBoost получает 0.28957 против 0.25312 у LightGBM только по анкете, то есть исторические признаки помогают не только глобальному ранжированию, но и выделению редкого рискованного класса.

Калибровочные кривые сильных моделей в целом близки к диагонали. У CatBoost Brier 0.06541 — немного лучше LightGBM (0.06606) и MLP (0.06757). На верхних квантилях риска остаются небольшие отклонения, поэтому для реального скоринга нужна отдельная калибровка на независимом временном holdout. Brier линейной модели и дерева напрямую сравнивать нельзя: `class_weight='balanced'` сдвигает их шкалу вероятностей.

7. MLP: анализ результата

MLP использует до 400 числовых признаков, выбранных внутри train-части каждого фолда, и архитектуру 512–256–128 с BatchNorm, Dropout, AdamW, weight decay и early stopping. Итоговый ROC-AUC — **0.76318**.

Кривые обучения показывают устойчивый разрыв: train AUC продолжает расти примерно до 0.80–0.82, тогда как validation AUC быстро выходит на плато около 0.76; train loss снижается, validation loss почти перестаёт улучшаться уже после первых эпох. Это классический признак роста variance. Early stopping действитель-

но ограничивает переобучение, но не устраняет структурное преимущество boosting.

Что означает отрицательный результат MLP

Нельзя делать общий вывод «нейросети хуже для таблиц». Конкретная MLP сознательно использует только 400 числовых признаков и не получает категориальные признаки в нативной форме, тогда как CatBoost использует всю матрицу. Поэтому результат показывает практическое преимущество boosting в данной постановке, а не фундаментальную невозможность neural network подхода.

8. Blend и проверка на Kaggle



Meta-CV выбирает LightGBM weight 0.15–0.20 на всех пяти фолдах; средний test weight равен 0.18. Стабильность веса показывает, что небольшой дополнительный сигнал LightGBM действительно есть, а не возникает только на одном фолде. Cross-fitted blend получает **0.79440 ROC-AUC**, PR-AUC 0.29067 и Brier 0.06536 — всего **+0.00035** к CatBoost.

На Kaggle CatBoost получает **0.79479 Public** и **0.79510 Private**; blend — 0.79466 и 0.79473. То есть локальный gain не переносится на внешний leaderboard. Это важнее самого +0.00035: при столь малой разнице выбор более простой самостоятельной модели оказывается устойчивее.

Близость OOF 0.79405 и Private 0.79510 также показывает отсутствие заметного оптимизма локальной схемы. Разница около 0.001 находится в масштабе обычной вариативности split/leaderboard, а не выглядит как сильный validation overfit.

Таблица 1: Сравнение моделей на одной 5-fold OOF-схеме. Время LightGBM не включает 40 Optuna trials.

Модель	ROC-AUC	PR-AUC	Brier	Время, с
CatBoost — заявка + история	0.79405	0.28957	0.06541	1384.7
LightGBM — заявка + история	0.78538	0.27810	0.06606	369.2
LightGBM — только заявка	0.76724	0.25312	0.06731	39.2
MLP — заявка + история	0.76318	0.24636	0.06757	288.9
Logistic Regression	0.75141	0.23143	0.20208	874.7
Decision Tree	0.72805	0.20346	0.20827	61.4

**Рис. 3:** OOF ROC-, Precision-Recall- и calibration-кривые. Исторические модели лучше baseline; CatBoost одновременно лидирует по ранжированию и имеет лучший Brier среди сильных моделей.**Рис. 4:** MLP: train AUC продолжает расти после выхода validation AUC на плато; validation loss стабилизируется заметно раньше train loss.

Submission and Description		Private Score	Public Score	Selected
	submission_catboost_v2.csv Complete (after deadline) · now	0.79510	0.79479	☐
	submission_crossfitted_blend_v2.csv Complete (after deadline) · 20s ago	0.79473	0.79466	☐

Рис. 5: Внешняя проверка. CatBoost v2 оказался лучше cross-fitted blend и на Public, и на Private leaderboard.

9. Какие источники истории дают качество

Group permutation importance считается на OOF validation: все признаки одной группы совместно переставляются, после чего измеряется падение ROC-AUC. Это отвечает на вопрос не «какой столбец чаще использует дерево», а «насколько модель теряет способность ранжировать клиентов, если разрушить информацию целого источника».

Текущая заявка даёт падение 0.15414 — ожидаемо, поскольку именно в ней находятся базовые параметры кредита и сильные *EXT_SOURCE*. Среди *исторических* источников лидируют bureau (0.01977), installments (0.01701) и previous applications (0.01491). POS/CASH и credit cards полезны слабее: 0.00732 и 0.00609. Интересно, что bureau содержит 1160 признаков, а installments — только 213, но их permutation drop близок. Это указывает на высокую «плотность» полезного сигнала в

фактической платёжной дисциплине. Одновременно нельзя сравнивать группы только по размеру: коррелирующие источники способны частично подменять друг друга, поэтому индивидуальный drop может недооценивать совместную ценность истории.

Для всех 1 082 v2-признаков drop равен 0.03981. Из конкретных семейств сильнее всего недавние временные окна — 0.01630. Взаимодействия анкеты дают 0.00511, договорные агрегаты 0.00224, последние 1/3/5 событий 0.00197.

Как правильно читать permutation importance

Большой drop всех v2-признаков не означает, что v2 добавила ровно 0.03981 к ROC-AUC: модель перестраивает использование коррелирующих признаков, а группы пересекаются. Для оценки чистого прироста данных надёжнее контролируемый эксперимент LightGBM «анкета vs история» (+0.01814). Permutation importance отвечает другому вопросу — от каких блоков уже обученная CatBoost наиболее зависит.

10. Интерпретация CatBoost и SHAP

Встроенный importance ставит на первое место `APP_EXT_SOURCE_MEAN`: его importance 6.64, что намного выше второго признака. Далее идут минимум/максимум внешних score, взаимодействие среднего `EXT_SOURCE` с возрастом, `CODE_GENDER`, произведение `EXT_SOURCE_2` и `EXT_SOURCE_3`, кредитно-товарный gap и показатели долговой нагрузки. Из истории в top-20 входит `INSTALLMENTS_AMT_PAYMENT_SUM`. SHAP позволяет посмотреть не только важность, но и направление вклада числовых признаков. На summary plot:

- высокие значения `APP_EXT_SOURCE_MEAN` в основном имеют отрицательный SHAP, то есть снижают прогнозируемый риск; низкие значения дают длинный положительный хвост и повышают score;
- `APP_EXT_SOURCE_MIN` ведёт себя аналогично: один очень низкий внешний score способен заметно сдвинуть прогноз в рискованную сторону;
- большой положительный `APP_V2_CREDIT_GOODS_GAP` чаще увеличивает прогноз риска;
- высокое `APP_ANNUITY_TO_INCOME` в среднем сдвигает score вверх, что согласуется с интерпретацией большей платёжной нагрузки;
- взаимодействие `APP_V2_EXT_MEAN_X_AGE`

показывает, что эффект внешнего score зависит от возраста, а не является чисто аддитивным.

Для категориальных признаков — пола, образования, occupation — цветовую шкалу beeswarm нельзя читать как обычное «больше/меньше»: категории не имеют естественного числового порядка. Их высокая важность означает лишь то, что модель использует различия между категориями. В частности, присутствие `CODE_GENDER` среди сильных признаков является дополнительной причиной отдельно анализировать fairness и в production проверять ablation чувствительного признака и его проху.

Главный смысл SHAP

Модель опирается не на один «магический» фактор. Доминирует внешний скоринг, но рядом с ним появляются долговая нагрузка, параметры кредита, возрастные взаимодействия и фактическая история платежей. Это согласуется с permutation analysis: анкета задаёт основной сигнал, а история уточняет ранжирование внутри похожих анкетных профилей.

11. Порог и структура ошибок

Для Kaggle threshold не нужен, но для диагностического разбора выбран порог 0.1499, максимизирующий F1 на OOF. Получены precision 0.2779, recall 0.4722, F1 0.3499 и FPR 0.1078. Модель правильно находит 11 723 дефолта, но пропускает 13 102; одновременно 30 468 хороших клиентов оказываются false positive.

Эти числа хорошо показывают, почему ROC-AUC и business threshold нельзя смешивать. При текущем пороге модель ловит меньше половины дефолтов. Снижение порога увеличивает recall, но резко увеличит число ложных отказов; повышение порога уменьшит FP, но пропустит ещё больше дефолтов. В production оптимизировать нужно ожидаемую денежную стоимость решений, а не F1.

Профили ошибок дают дополнительную интерпретацию. TP и FP почти совпадают по медианному возрасту (36.7 и 36.6 года) и credit-to-income (3.19 и 3.18). Даже медианный `EXT_SOURCE` близок: 0.304 против 0.327. Значит, многие FP действительно выглядят как дефолтные клиенты по главным признакам, и их нельзя устранить простым правилом по одному показателю.

FN, наоборот, имеют медианный `EXT_SOURCE` равен 0.485 — ниже TN (0.553), но заметно выше TP/FP. Это «пограничные» дефолты, которые




Рис. 6: Group permutation importance. Среди исторических источников сильнее всего bureau, installments и previous applications; среди v2-признаков — недавние временные окна.




Рис. 7: Слева — CatBoost feature importance; справа — SHAP summary первой fold-модели. Для числовых признаков цвет показывает значение признака, положение по оси X — направление локального вклада в model output.

выглядят достаточно надёжно для модели. Их медианный возраст 41.7 года против 36.7 у TP; это согласуется с fairness-анализом, где recall снижается в старших возрастных группах.

12. Fairness-диагностика

При одном глобальном пороге у женщин default rate 7.00%, positive prediction rate 10.74%, TPR 42.22%, FPR 8.38%, ROC-AUC 0.79304. У мужчин default rate выше — 10.14%, модель помечает положительными 19.45%, TPR 53.88%, FPR 15.57%, ROC-AUC 0.78518.

То есть мужчины получают положительный

прогноз примерно в 1.8 раза чаще. Часть различия ожидаема из-за base rate, который у мужчин примерно в 1.45 раза выше, но этим объясняется не всё: FPR выше на 7.19 п.п., TPR — на 11.66 п.п.. При этом threshold-free ROC-AUC у мужчин даже немного ниже. Следовательно, различие operating point связано не с тем, что модель «лучше распознаёт мужчин», а с распределением scores, base rate и используемыми признаками.

PR-AUC у мужчин выше (0.31377 против 0.27043), однако эту метрику нельзя сравнивать между группами без оговорки: PR-AUC зависит




Рис. 8: Слева — выбор диагностического порога и confusion matrix; справа — профили TP/TN/FP/FN. Ошибки сильнее различаются по model score и EXT_SOURCE, чем по медианному credit-to-income.

от prevalence, а дефолт у мужчин встречается чаще.

По возрасту positive rate уменьшается с 28.05% в группе 18–25 до 2.03% у 65+, параллельно снижению base rate. Но TPR падает ещё сильнее: с 57.51% до 12.85%. Одновременно FPR снижается с 23.92% до 1.62%. Один и тот же threshold фактически задаёт очень разные operating points для возрастных групп.

Важнее, что различается и ROC-AUC, не зависящий от threshold: 0.74466 у 18–25, максимум 0.79865 у 35–45, затем 0.76361 у 55–65 и 0.76892 у 65+. Значит, на крайних возрастах различия связаны не только с выбором порога, но и с менее устойчивым ранжированием. При этом группы 18–25 и 65+ заметно меньше центральных возрастных групп, поэтому для строгого аудита нужны bootstrap confidence intervals.

Что проверять дальше в production

Fairness-таблица — диагностика, а не доказательство дискриминации. Следующие проверки: калибровка внутри групп, доверительные интервалы метрик, ablation CODE_GENDER, поиск проху-признаков, стабильность разрывов во времени и оценка бизнес-последствий. Выбор group-specific thresholds без юридической и продуктовой оценки сам по себе не является корректным «исправлением» fairness.




Рис. 9: Fairness по возрасту при едином threshold. С возрастом снижаются base rate и positive rate, но одновременно резко падает TPR; ROC-AUC хуже на крайних возрастных группах.

Таблица 2: Fairness-диагностика по возрасту.

Возраст	<i>n</i>	Default	Positive	TPR	FPR	ROC-AUC
18–25	12 233	12.29%	28.05%	57.51%	23.92%	0.74466
25–35	72 429	10.66%	21.29%	55.90%	17.16%	0.78579
35–45	84 261	8.41%	14.01%	47.96%	10.89%	0.79865
45–55	70 190	7.05%	10.86%	43.29%	8.41%	0.79222
55–65	60 522	5.42%	6.20%	29.44%	4.87%	0.76361
65+	7 876	3.66%	2.03%	12.85%	1.62%	0.76892

13. Итоги и ограничения

Главный результат проекта — не только финальный ROC-AUC, а объяснимая структура прироста качества. Переход от Logistic Regression к LightGBM по анкете даёт +0.01583, подключение подробной истории тому же LightGBM — ещё +0.01814, переход к CatBoost — +0.00867. История является одним из основных источников качества, а не небольшим дополнением.

Permutation analysis уточняет этот вывод: среди исторических источников сильнее всего bureau, installments и previous applications; среди новых семейств признаков — недавние временные окна. SHAP показывает, что основной сигнал по-прежнему задают внешние score и их взаимодействия, а история и финансовая нагрузка уточняют прогноз. Error analysis показывает, что FP действительно похожи на дефолты по доминирующим score, а FN чаще имеют промежуточный риск-профиль и старший возраст.

Cross-fitted blend дал лишь +0.00035 OOF и проиграл CatBoost на Kaggle. Поэтому финальной моделью выбран CatBoost: **0.79405 OOF**, **0.79479 Public**, **0.79510 Private**. Близость OOF

и Private подтверждает, что локальная оценка не выглядит существенно завышенной.

Fairness-анализ выявил заметно разные operating points по полу и особенно по возрасту. Это не позволяет автоматически говорить о дискриминации, но показывает, что единый threshold ведёт себя неодинаково и что на крайних возрастных группах снижается даже threshold-free ROC-AUC. Для реального кредитного решения этот блок потребовал бы отдельного статистического и юридического аудита.

Ключевые ограничения проекта: случайная, а не временная CV; конкурсный характер данных; отсутствие бизнес-функции стоимости ошибок; отсутствие отдельного calibration holdout; использование EXT_SOURCE уже в «application-only» постановке. Для production дополнительно нужны temporal validation, drift monitoring, calibration, cost-sensitive threshold selection, stability tests, explainability отдельных решений и расширенный fairness-аудит.

Источник данных: Kaggle, Home Credit Default Risk. Все численные результаты, таблицы и графики получены из финального notebook проекта. [Страница соревнования](#).